

HƯỚNG DẪN THỰC HIỆN ĐỒ ÁN GIỮA KỲ

CÔNG ĐOẠN OCR – DÓNG HÀNG DỊCH ÂM, DỊCH NGHĨA HÁN NÔM

Sắp xếp bbox, đóng hàng, đối sánh

I. DÓNG HÀNG OCR VÀ DỊCH ÂM

OCR, sẽ gồm 2 bước:

- Bước 1: Nhận diện từng cột/hàng ảnh (gọi là detection, cho ra kết quả là các khung chữ nhật có viền bao quanh, gọi là bounding box). Các văn bản xưa sẽ chủ yếu viết theo cột.
- Bước 2: Nhận diện từng ký tự trong bbox đó để cho ra từng ký tự (ở đây là Hán tự hay Nôm tự). Bước là gọi là Recognition.

Qua thực tế sử dụng các công cụ OCR văn bản Hán Nôm (như: PPOCRLabel của Paddle OCR, KanDianGuJi, CLC, ...) chúng ta thấy các bbox cũng như các ký tự nhận diện được có thể chưa chính xác (tùy vào chất lượng ảnh). Bbox có thể bị nhận diện sai/thiếu/thừa hay không đúng thứ tự (từ trên xuống dưới và từ trái sang phải theo cách viết chữ Hán xưa) và các Hán/Nôm tự có thể bị OCR ra sai/thiếu/thừa. Vì vậy, các bạn cần phải tiến hành các công đoạn sau:

1. Sắp xếp các box theo đúng thứ tự (phải qua trái, trên xuống): Dựa vào tọa độ (lưu ý đến độ lệch)
2. Đóng hàng các box (box alignment) theo các câu dịch của chữ Quốc ngữ: Dựa vào chiều dài tương ứng của từng box với chiều dài câu QN.
3. Đóng hàng từng chữ Hán Nôm được OCR ra với từng chữ QN tương ứng trong 1 box (char alignment): Dựa vào giải thuật M.E.D Levenshtein. Trong đó, việc so sánh 2 chữ Hán Nôm (gọi là **sn**) và chữ Quốc ngữ (gọi là **qn**) cần đóng hàng được thực hiện bằng cách lấy phần giao giữa 2 tập **S1** và **S2**, trong đó:

S1 = {tập những chữ Hán Nôm có hình dáng tương đồng với chữ **sn** (dùng tự điển **SinoNom_Similar.dic**)}

S2 = {tập những chữ Hán Nôm khả dĩ được dịch từ 1 chữ **qn** (dùng tự điển **QuocNgu_SinoNom.dic**)}

Cụ thể gồm các bước sau:

- Nếu chữ **sn** $\in$ **S2** => xem như đã OCR đúng (ko tô màu, vẫn để màu đen).
- Nếu chữ **sn** $\notin$ **S2** => Lấy phần giao **S1** $\cap$ **S2** => xét 3 khả năng sau:
 - a. Nếu kết quả giao = 1: Đó chính là chữ OCR đúng và trùng với chữ QN tương ứng (tô màu xanh) .
 - b. Kết quả giao > 1: Lấy chữ OCR có độ tương đồng cao nhất (tính từ trái sang phải trong tập **S1**) và chữ đó cũng được xem là OCR đúng (tô màu xanh).
 - c. Kết quả giao = 0: Không xác định. Tô màu đỏ. Xem đó là chữ OCR sai.

Ví dụ: cặp chữ đầu tiên trong box đầu tiên của Truyện Kiều, ta có:


chữ **sn** là “𣎵” có **S1** = { '廐', '度', '稅', '脣', '賸', '梶', '板', '朽', '稊', '穢', '穢', '榑', '榑', '榑', '榑', '磨', '稂', '穢', '庚', '快', '算' } (dựa trên tự điển “SinoNom Similar.dic”)

chữ **qn** là “𣎵” có **S2** = { 𣎵, 林, 百, 𣎵, 𣎵, , } (dựa trên tự điển “QuocNgu SinoNom.dic”)

Khi đó, chữ sn (“𣎵”) thuộc tập S2 (chữ thứ 4) => đây là chữ OCR đúng và trùng với chữ QN “𣎵” (ko tô màu).

II. DÓNG HÀNG OCR, DỊCH ÂM VÀ DỊCH NGHĨA

a. Ta có ảnh văn bản Hán Nôm: (như hình dưới). Văn bản Hán Nôm xưa chủ yếu viết dạng dọc theo từng cột từ phải sang trái, từ trên xuống dưới (nếu cùng cột).



b. Sau khi gọi API OCR, qua phần detection, chúng ta có kết quả bounding box như sau: (gồm 5 bbox, mỗi bbox được xác định bằng tọa độ 4 góc)



c. Danh sách các bbox sau công đoạn Detection:

[(341, 8), (379, 8), (379, 149), (341, 149)]

[(261, 9), (297, 9), (297, 251), (261, 251)]

[(181, 6), (219, 6), (219, 252), (181, 252)]

[(102, 9), (137, 9), (137, 250), (102, 250)]

[(20, 9), (55, 8), (57, 250), (23, 250)]

d. Sau đó, qua công đoạn Recognition của OCR, ta có kết quả các ký tự (Hán Nôm tự) trong các bbox đó.

Chúng ta sẽ tổng hợp tất cả các kết quả OCR (gồm bbox và các ký tự Hán Nôm), dịch âm, dịch nghĩa như sau:

	A	B	C	D	E
1	ID	Image box	SinoNom char	Âm Hán Việt	Nghĩa thuần Việt
2	LBA_023.001.01	[(341, 8), (379, 8), (379, 149), (341, 149)]	南國山河	Nam quốc sơn hà	Sông núi nước Nam
3	LBA_023.001.02	[(261, 9), (297, 9), (297, 251), (261, 251)]	南國山河南帝居	Nam quốc sơn hà nam đế cư	Sông núi nước Nam vua Nam ở
4	LBA_023.001.03	[(181, 6), (219, 6), (219, 252), (181, 252)]	截然定分在天書	Tiệt nhiên định phận tại thiên thư	Cương giới đã ghi rành rành trong sách Trời
5	LBA_023.001.04	[(102, 9), (137, 9), (137, 250), (102, 250)]	如何逆虜來侵犯	Như hà nghịch lỗ lai xâm phạm	Cớ sao lũ giặc bạo ngược kia dám tới xâm phạm
6	LBA_023.001.05	[(20, 9), (55, 8), (57, 250), (23, 250)]	汝等行看取敗虛	Thử đẳng hành khan thủ bại hư	Chúng bay hãy chờ xem, thế nào cũng chuốc lấy bại vong

e. Về mã số trong ID:

Cột ID (mã số): gồm 14 ký tự, thuộc 7 trường với ý nghĩa như sau (từ trái sang phải):
DSG_fff.ccc.ppp.ss

1. D: Domain: chỉ lĩnh vực, như: văn học (L), lịch sử (H), y học (M), tôn giáo (R), ...
A: Administration: sắc phong, chiếu chỉ, kế ước, thạc bản văn bia
B: Base: tổng hợp
C: Culture: phong tục: ma chay, cưới hỏi; thờ cúng, sinh hoạt hàng ngày, bói toán
D: Dictionary: Từ điển, ngôn ngữ
G: Geography: dư địa chí, địa lý,
H: History: lịch sử
L: Literature: văn học, nghệ thuật, đời sống, âm nhạc, ca trù,
M: Medicine: y học dân tộc
O: Others:
P: Triết học
R: Religion: tôn giáo
S: Scene: ngoại cảnh: hoành phi, câu đối; bia mộ, khắc trên chuông, trống, bài vị, các dụng cụ
T: Technique: kỹ thuật (toán, nông, thiên văn - lịch)
W: laW: pháp luật
2. S: Sub-domain: chỉ lĩnh vực con, như: trong nhóm R (Tôn giáo), thì có: RB (Phật giáo), RC (Công giáo),...
3. G: Genre: chỉ thể loại: Hán/Nôm, Văn/Xuôi; Dọc/Ngang; Khắc-In/Viết-tay; niên đại
4. fff: #số hiệu file ngữ liệu thô trong lĩnh vực con đó
5. ccc: #số hiệu chapter (số tập/số chương/hồi/đoạn/...) trong file đó
6. ppp: #số page trong chapter đó
7. ss: #số sentence hay số box trong page đó.

=> T sẽ cung cấp cho từng tác phẩm mã số DSG_fff, còn các số còn lại các bạn tự đánh số như T đã giải thích ở trên.

III. DÓNG HÀNG DỊCH NGHĨA

Với chữ Nôm thì chỉ có dịch âm (chuyển tự), với chữ Hán ta có thể có Dịch âm (âm Hán Việt) và Dịch nghĩa (dùng từ thuần Việt). Ta có một số phương pháp dóng hàng Dịch nghĩa như sau:

1. Dictionary-based: dựa vào tự điển Hán-Việt hay Việt-Hán để tra từng chữ rồi lấy phần giao giữa tập nghĩa Việt của chữ Hán nguồn đó với nghĩa tiếng Việt đích hay ngược lại (tập nghĩa Hán của chữ Việt đích với chữ Hán nguồn). Sau đó tính tỉ lệ giao để chọn cặp câu có tỉ lệ giao cao nhất. Trong phương pháp này, chúng ta cũng có thể dựa vào một số điểm neo (anchor) bất biến giữa câu nguồn Hán và câu đích Việt, như: tên riêng, con số, ngày tháng, ...
2. Dịch nghĩa tự động câu Hán (bằng API) sang tiếng Việt rồi so sánh độ tương đồng giữa câu tiếng Việt đó với câu tiếng Việt đích cần dóng.
3. Độ đo cosine giữa 2 vector (là câu Hán và câu Việt) qua một số mô hình như: BERT align, Vec Align,

Lưu ý:

- a. Cần phải tách câu bên phía chữ Hán và chữ Việt trước khi tiến hành dóng hàng.
- b. Việc dóng hàng câu Dịch nghĩa có thể không phải là ánh xạ 1-1, mà có thể là m-n (m câu Hán dóng với n câu Việt).