

YÊU CẦU CỦA ĐỒ ÁN GIỮA KỲ

A. VỀ YÊU CẦU

1. **HVQ**: Xây dựng ngữ liệu đơn ngữ chữ Quốc ngữ chuyên ngành lịch sử VN
 - a. Đầu vào Ảnh: Yêu cầu OCR, sửa lỗi chính tả và tách câu
 - b. Đầu vào Text: Yêu cầu tách câu và NER
2. **HVH**: Xây dựng ngữ liệu đơn ngữ chữ Hán chuyên ngành lịch sử VN
 - a. Đầu vào Ảnh: Yêu cầu OCR, tách câu
 - b. Đầu vào Text: Yêu cầu tách câu và NER
3. **HVB**: Xây dựng ngữ liệu song song Hán - Việt chuyên ngành lịch sử VN
 - a. Đầu vào Ảnh: Yêu cầu OCR, tách câu, đóng hàng
 - b. Đầu vào Text: Yêu cầu tách câu và đóng hàng
4. **HCB**: Xây dựng ngữ liệu song song Hán - Việt chuyên ngành lịch sử TQ
 - a. Đầu vào Ảnh: Yêu cầu OCR, tách câu, đóng hàng
 - b. Đầu vào Text: Yêu cầu tách câu và đóng hàng
5. **HCH**: Xây dựng ngữ liệu đơn ngữ chữ Hán chuyên ngành lịch sử TQ
 - a. Đầu vào Ảnh: Yêu cầu OCR, tách câu
 - b. Đầu vào Text: Yêu cầu tách câu và NER

B. VỀ CÔNG CỤ

Không giới hạn công cụ, mô hình hay phương pháp thực hiện. Nhóm có thể chủ động lựa chọn, kết hợp hoặc đề xuất các giải pháp phù hợp nhằm đạt chất lượng dữ liệu tốt nhất. Một số công cụ tham khảo:

- OCR: KanDianGuJi, PaddleOCR, Google Vision OCR, ChatGPT, Gemini...
- Hiệu đính OCR: ChatGPT, Gemini, DeepSeek, Qwen...
- Tách câu: Underthesea, VnCoreNLP... hoặc các phương pháp dựa trên LLM.
- NER: PhoBERT, HanLP, CKIP hoặc các mô hình LLM...
- Đóng hàng: BERTAlign, LaBSE, Vecalign, SimAlign hoặc các phương pháp dựa trên embedding/LLM.